Questionário (ref. Aulas 01 a 08)

Capítulo I – O que é análise de dados

1) O que análise de dados?

É o processo de exame sistemático dos dados com o objetivo de extrair informações relevantes para apoiar a tomada de decisão. Envolve etapas como entendimento do problema, pré-processamento dos dados, análise e compartilhamento, permitindo identificar padrões e gerar insights.

2) O que é análise descritiva?

É o tipo de análise que resume e organiza dados históricos para mostrar o que aconteceu. Seu objetivo é descrever o comportamento passado por meio de métricas, indicadores e visualizações, como relatórios e dashboards, permitindo acompanhar desempenho, volumes, tendências e padrões observados, sem buscar explicações causais ou previsões futuras.

3) O que é análise diagnóstica?

É o tipo de análise que busca explicar por que determinado evento ocorreu, investigando causas, relações e fatores associados. Envolve a exploração de correlações, segmentações e comparações entre variáveis, permitindo identificar padrões que ajudem a entender os motivos por trás dos resultados observados.

4) O que é análise preditiva?

É o tipo de análise que utiliza padrões identificados nos dados históricos para estimar o que pode acontecer no futuro. Para isso, emprega modelos estatísticos e técnicas de machine learning, permitindo prever comportamentos, probabilidades e valores futuros, como churn, demanda, inadimplência ou receita.

5) O que é análise prescritiva?

É o tipo de análise que recomenda ações a serem tomadas com base em previsões e cenários. Considera objetivos, restrições e possíveis impactos das decisões, podendo utilizar técnicas de otimização, simulação ou regras de negócio para indicar a melhor alternativa a ser adotada.

6) Qual a principal diferença entre análise descritiva, diagnóstica, preditiva e prescritiva?

A análise descritiva mostra o que aconteceu, a diagnóstica explica por que aconteceu, a preditiva estima o que pode acontecer e a prescritiva recomenda o que deve ser feito. Essas análises representam níveis crescentes de maturidade no uso de dados, indo da descrição do passado até o apoio à tomada de decisão.

7) O que é EDA (Análise Exploratória de Dados)?

Questionário (ref. Aulas 01 a 08)

Não é um tipo de análise por si só. Trata-se de uma abordagem transversal usada para investigar dados (padrões, distribuições, outliers, relações) em qualquer tipo de análise (descritiva, diagnóstica, preditiva ou prescritiva).

8) Porque a análise preditiva é mais "famosa" atualmente?

A análise preditiva ganhou destaque por utilizar ML/IA para antecipar eventos, tornando-se diferencial competitivo. Enquanto as análises descritivas e diagnósticas já existiam e estavam consolidadas antes mesmo do uso de IA (DW, Data Mart, mineração de dados), a análise preditiva representa o estágio atual de evolução das organizações, que ainda estão incorporando ML/IA (etapa necessária a viabilização da análise prescritiva). Ou seja, a análise preditiva é o "estado da arte".

Capítulo II – Processo de análise de dados

1) Historicamente, o processo de análise de dados foi estruturado em etapas que organizam o trabalho desde o entendimento até a interpretação dos resultados. Cite exemplos de modelos/metodologias.

KDD Process (Knowledge Discovery in Databases): processo de descoberta de conhecimento em bases de dados que envolve seleção dos dados, pré-processamento, transformação, mineração de dados e interpretação/avaliação dos resultados. CRISP-DM (Cross Industry Standard Process for Data Mining): metodologia de mineração de dados com seis etapas principais: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação. SEMMA (Sample, Explore, Modify, Model, Assess): metodologia usada em mineração de dados criada pelo SAS (originalmente significava Statistical Analysis System) que inclui amostragem dos dados, exploração inicial, modificação/preparação, construção de modelos e avaliação do desempenho dos modelos.

2) No curso adotamos um ciclo de vida para projetos de análise de dados composto por seis macroetapas. Quais são essas etapas?

No curso adotamos as etapas: entender, preparar, processar, analisar, compartilhar e implementar.

3) Qual é o objetivo da etapa Entender em análise de dados?

Definir o problema analítico e as perguntas que serão respondidas com os dados. Em análise preditiva, por exemplo, definir se o objetivo é prever churn, inadimplência, demanda ou LTV.

4) Qual é o objetivo da etapa Preparar em análise de dados?

Questionário (ref. Aulas 01 a 08)

Identificar e viabilizar as fontes de dados. Verificar se os dados existem, onde estão armazenados, como acessá-los, questões de governança, privacidade e autorização de uso. Em análise preditiva, envolve definir quais dados históricos (janela de observação) serão usados e "quanto futuro" se pretende prever (horizonte de observação).

5) Qual é o objetivo da etapa Processar em análise de dados?

Realizar limpeza e preparação técnica dos dados para garantir qualidade e consistência. Envolve tratamento de valores ausentes, correção de inconsistências, padronização de formatos, remoção de duplicidades e validações estruturais. Em análise preditiva, essa etapa assegura que os dados estejam confiáveis para uso posterior, sem ainda aplicar lógica de modelagem, ou seja, transformações que independem do modelo.

6) Qual é o objetivo da etapa Analisar em análise de dados?

Aplicar métodos analíticos e construir modelos para extrair padrões ou realizar previsões a partir dos dados. É nessa etapa que técnicas de machine learning são efetivamente utilizadas. Em análise preditiva, envolve a construção de atributos, a codificação de variáveis categóricas, transformações matemáticas, escalonamento, seleção e redução de atributos, além da escolha de algoritmos, treinamento, validação e teste, produzindo previsões e métricas de desempenho.

7) Qual é o objetivo da etapa Compartilhar em análise de dados?

Comunicar os resultados da análise de forma clara para apoiar interpretação e tomada de decisão. Essa etapa normalmente envolve a integração com ferramentas de visualização e comunicação de dados, como Tableau ou Microsoft Power BI. Em análise preditiva, inclui apresentar métricas (acurácia, AUC, erro), limitações do modelo e implicações práticas.

8) Qual é o objetivo da etapa Implementar em análise de dados?

Aplicar os resultados da análise em um contexto real de uso. Essa integração pode ocorrer de diferentes formas, como a geração pontual de resultados a partir do modelo, execuções periódicas em processos automatizados (lotes) ou integração direta em sistemas que realizam inferência em tempo real. Em análise preditiva, envolve colocar o modelo em produção, seja por execuções em lote, integração em sistemas ou inferência em tempo real, além de monitorar desempenho e efeitos das decisões ao longo do tempo.

Capítulo III – Formulação do problema preditivo

Questionário (ref. Aulas 01 a 08)

1) Por que problemas de análise preditiva normalmente são formulados como problemas de aprendizado supervisionado?

Porque existe uma variável-alvo explícita a ser estimada a partir de dados históricos. Embora existam exceções, a maioria dos problemas preditivos se enquadra em aprendizado supervisionado, pois o modelo aprende a mapear entradas (variáveis explicativas) para um resultado conhecido.

2) Quais são os tipos de tarefa/problema que surgem nesse contexto?

O aprendizado supervisionado divide a análise preditiva em problemas de regressão (valor contínuo) e problemas de classificação (classe/categoria).

3) O que são perguntas analíticas?

São questões formuladas de forma clara, mensurável e orientada a dados, que permitem serem operacionalizadas em variáveis, métricas ou modelos. Elas estruturam o problema analítico e definem elementos como unidade de análise, variável-alvo e horizonte temporal.

4) Escreva 2 exemplos de perguntas analíticas:

   a. Descritivas

   – Qual foi a receita mensal no último ano?

   – Qual foi nossa taxa de cancelamento mensal ano passado?

   b. Diagnósticas

   – Que fatores explicam a queda da receita no último trimestre?

   – Quais fatores estão associados ao aumento de churn?

   c. Preditivas

   – Quais clientes têm maior probabilidade de cancelar em 30 dias?

   – Qual é o LTV de nossos clientes por nicho?

   d. Prescritivas

   – Que ações podem reduzir o churn em 30% no próximo ano?

   – Quanto devo aumentar o preço para maximizar a receita?

5) O que é a unidade de análise?

É a entidade sobre a qual a previsão será feita e define a granularidade do problema. Determina como os dados serão organizados (linhas da base) e influencia todas as demais definições. Ex.: prever churn por cliente (uma linha por cliente, agregando suas transações) versus prever fraude por transação (uma linha por transação, com repetição do cliente quando houver múltiplas transações).

6) O que é variável-alvo?

É o resultado futuro associado à unidade de análise que o modelo tenta estimar. Deve ser mensurável e definido no tempo. Ex.: "inadimplente em 90 dias", "cancelou em 30 dias", "valor gasto no próximo mês".

Questionário (ref. Aulas 01 a 08)

7) O que é variável explicativa?

São as variáveis observáveis antes do evento que ajudam a prever o alvo. Devem estar disponíveis no momento da previsão. Ex.: renda, idade, histórico de compras, número de atrasos anteriores.

8) O que é horizonte de previsão?

Intervalo entre o momento em que a previsão é feita e o evento que se deseja estimar. Define "até quando" se quer prever. Ex.: prever churn em 30 dias, inadimplência em 90 dias.

9) O que é janela de observação?

Período do passado usado para construir as variáveis explicativas. Define "de onde vêm os dados". Ex.: usar últimos 6 meses de histórico para prever comportamento futuro.

10) A mudança da unidade de análise pode alterar a variável-alvo?

Sim. Porque o alvo está diretamente vinculado à unidade de análise. Ao mudar a unidade, muda também o que está sendo previsto. Ex.: se a unidade é cliente, a variável-alvo pode ser churn do cliente; se a unidade é transação, a variável-alvo passa a ser fraude da transação.

11) A mudança da unidade de análise pode alterar o conjunto de variáveis explicativas?

Sim. Pelo mesmo motivo: ao mudar a unidade de análise, muda a forma de construção das variáveis explicativas. Ex.: se a unidade é o cliente, as variáveis de várias transações precisam ser agregadas (média de gasto, total de compras); se a unidade é a transação, utilizam-se atributos diretos de cada transaão (valor da compra, forma de pagamento).

12) O que é vazamento de informação?

O vazamento de informação ocorre quando o modelo utiliza variáveis que não estariam disponíveis no momento real da previsão ou que incorporam, direta ou indiretamente, o próprio resultado a ser previsto, gerando desempenho artificial. Em problemas preditivos, o correto é utilizar apenas variáveis que existiam no instante da previsão. Isso acontece porque, ao trabalhar com dados históricos, algumas variáveis aparecem no dataset justamente porque foram registradas após o evento (e muitas vezes são usadas como rótulo), mas não podem ser usadas como explicativas. Por exemplo, ao prever se um cliente ficará inadimplente em 90 dias, utilizar uma variável como "valor pago após atraso" caracteriza.

13) O que é uma variável irrelevante?

É qualquer variável que não apresenta relação estatística significativa com a variável-alvo e, portanto, não contribui para reduzir sua incerteza. Seu

uso tende a introduzir ruído, aumentar a complexidade do modelo e prejudicar a interpretabilidade, sem ganho preditivo. Ex.: identificadores como ID do cliente, códigos administrativos e chaves de relacionamento (primárias e estrangeiras), que servem para identificação/integração de dados, mas não explicam o fenômeno a ser previsto.

14) O que é uma variável redundante?

É uma variável que carrega essencialmente a mesma informação de outra já presente no conjunto de dados, sem acrescentar ganho preditivo relevante. Isso ocorre, em geral, quando há alta correlação ou dependência entre variáveis, fazendo com que ambas representem o mesmo fenômeno sob formas diferentes. O uso simultâneo aumenta a complexidade e pode dificultar a interpretação do modelo. Ex.: idade e ano de nascimento, ou renda mensal e renda anual.

15) O que é uma variável inviável (ou indisponível)?

É uma variável que até pode existir no dataset histórico, mas não estará disponível no momento em que o modelo for aplicado em produção. Isso ocorre quando a variável depende de coleta pontual, processo manual ou informação que não faz parte do fluxo operacional. Embora não seja vazamento de informação, seu uso torna o modelo impraticável, pois não será possível reproduzir as mesmas entradas no uso real. Ex.: resultado de uma pesquisa específica que não é coletada continuamente.

16) O que é uma variável instável?

É uma variável cujo comportamento muda ao longo do tempo, fazendo com que os padrões aprendidos no passado deixem de representar adequadamente o futuro (drift). Essas mudanças podem ocorrer por alterações no contexto, como mercado, políticas ou comportamento dos usuários, reduzindo a capacidade de generalização do modelo. Parte dessas mudanças pode ser previsível e estruturada, como sazonalidade (ex.: aumento de compras na Black Friday), devendo ser incorporada ao modelo por meio de variáveis adequadas; outras são não antecipáveis (concept drift), exigindo monitoramento e re-treinamento. Assim, a instabilidade não é apenas um problema, mas uma característica inerente a muitos cenários reais, demandando atualização contínua dos modelos.

Capítulo IV – Engenharia de atributos

1) O que é engenharia de atributos?

Questionário (ref. Aulas 01 a 08)

É o processo de criação, transformação e seleção de variáveis com o objetivo de melhorar o desempenho dos modelos, tornando os dados mais adequados para aprendizado.

2) O que é construção de atributos?

É a criação de novas variáveis a partir das variáveis existentes, com o objetivo de representar melhor o fenômeno, ou seja, explicar melhor a variável alvo, e facilitar o aprendizado do modelo.

3) Explique esses tipos de construção de atributos:
    a. Combinações

    Consiste em combinar duas ou mais variáveis para gerar uma nova (ex.: renda total, razão entre variáveis).

    b. Agregações

    Consiste em resumir informações, geralmente ao agrupar dados (ex.: média, soma, contagem por cliente).

    c. Discretização

    Consiste em transformar uma variável contínua em faixas/categorias (ex.: idade → jovem, adulto, idoso).

4) O que é codificação de variáveis categóricas?

É o processo de transformar variáveis categóricas em valores numéricos para que possam ser utilizadas pelos modelos.

5) Explique esses tipos de codificações:
    a. Codificação One-Hot

    Cria uma variável binária para cada categoria, indicando presença ou ausência (0 ou 1).

    b. Codificação ordinal

    Atribui valores numéricos às categorias, respeitando uma ordem quando ela existe.

6) O que são transformações matemáticas?

São operações aplicadas às variáveis para alterar sua escala ou distribuição, visando melhorar o comportamento do modelo.

7) Explique esses tipos de transformações matemáticas:
    a. Transformação logarítmica

    Reduz a assimetria de distribuições e comprime valores altos, sendo útil quando há grande variação ou outliers.

8) O que é escalonamento?

É o processo de ajustar a escala das variáveis para torná-las comparáveis e evitar que algumas dominem o modelo.

9) Explique esses tipos de escalonamento:

Questionário (ref. Aulas 01 a 08)

a. Normalização

Transforma os dados para um intervalo fixo, geralmente entre 0 e 1.

b. Padronização

Transforma os dados para média 0 e desvio padrão 1.

10) O que é seleção de atributos?

É o processo de escolher um subconjunto de variáveis relevantes, eliminando aquelas que não contribuem para o modelo.

11) O que é redução de atributos?

É o processo de diminuir o número de variáveis, criando novas representações a partir das variáveis originais que preservam a maior parte da informação dos dados. No PCA, é possível controlar explicitamente o quanto de informação será mantido, escolhendo o percentual de variância explicada desejado.

12) Explique esses tipos de seleção e redução de atributos:

a. Correlação

Remove variáveis altamente correlacionadas para evitar redundância.

b. Informação mútua

Mede a dependência entre variáveis e a variável-alvo, ajudando a selecionar as mais relevantes.

c. PCA

Transforma o conjunto original de variáveis em novos componentes que capturam a maior parte da variância dos dados, reduzindo dimensionalidade.

Capítulo V – Especificação de modelos

1) Cite 2 modelos supervisionados clássicos utilizados em ANP.

Regressão Logística e Regressão Linear.

2) Cite 1 técnica não supervisionada utilizada em ANP.

PCA (Análise de Componentes Principais).

Obs. O PCA às vezes é citado como "modelo" em sentido amplo, pois ajusta parâmetros a partir dos dados e aprende uma representação. No entanto, não é um modelo preditivo, pois não estima uma variável-alvo (y). Rigorosamente, trata-se de uma técnica de redução de dimensionalidade utilizada como apoio na engenharia de atributos.

3) O que são algoritmos baseline no contexto de machine learning?

Questionário (ref. Aulas 01 a 08)

Baseline (ou linha de base) é um modelo inicial, simples e funcional, usado como referência antes da adoção de soluções mais complexas.

Regressão logística

4) O que é o modelo de regressão logística e por que ele é chamado de "regressão"?

É um classificador supervisionado que estima a probabilidade de uma observação pertencer à classe positiva a partir de uma combinação linear das variáveis de entrada, aplicando uma função sigmoide (ou softmax) para obter probabilidades. Ele é chamado de "regressão" porque realiza regressão linear internamente ($z = w \cdot x + b$) antes de aplicar a função sigmoide (ou softmax). Ou seja, o termo "regressão" vem da transformação linear interna e não do fato de o modelo ser utilizado para prever valores contínuos, já que é aplicado em classificação.

5) Por que a regressão logística é muito usada como baseline em análise preditiva?

Porque é um modelo simples, rápido e estável, que fornece uma referência inicial para problemas de classificação. Além disso, possui boa interpretabilidade, permitindo analisar o impacto das variáveis na probabilidade estimada, o que facilita sua utilização como modelo inicial de referência antes da aplicação de modelos mais complexos.

6) Como a regressão logística realiza a predição e qual é o papel da função sigmoide nesse processo?

O modelo calcula inicialmente uma combinação linear dos atributos ($z = w \cdot x + b$), cujo resultado pode variar de $-\infty$ a $+\infty$. Em seguida, aplica a função sigmoide para transformar esse valor em uma probabilidade entre 0 e 1, que representa a chance de a observação pertencer a uma determinada classe e é utilizada na decisão final.

7) Qual é a regra de decisão na regressão logística? Este limiar é fixo?

A regressão logística produz a probabilidade de uma observação pertencer à classe positiva (classe 1). A decisão final é feita comparando essa probabilidade com um limiar (geralmente 0,5). Valores acima do limiar são classificados como classe positiva, e abaixo, por consequência, como classe negativa. Esse limiar não é fixo e pode ser ajustado (ex.: 0,3 ou 0,7) conforme o contexto do problema (custo do erro etc.).

8) O que significa o custo do erro neste contexto?

O custo do erro refere-se ao impacto de classificações incorretas (falsos positivos e falsos negativos) no problema. Em ANP, alguns problemas possuem baixo custo de erro (ex.: classificação simples), enquanto outros

possuem alto custo (ex.: fraude, inadimplência). O limiar deve ser ajustado conforme esse custo e as regras de negócio: limiar mais baixo torna o modelo mais agressivo; limiar mais alto torna o modelo mais conservador.

9) O que é interpretabilidade no contexto de aprendizagem de máquina?
Interpretabilidade é a capacidade de um modelo ser compreendido e explicado por humanos, incluindo como ele utiliza as variáveis para gerar suas previsões. Modelos clássicos tendem a ser mais interpretáveis do que modelos modernos, como redes neurais.

Regressão linear

10) O que é o modelo de regressão linear e por que ele é chamado de "linear"?
É um modelo supervisionado utilizado para prever valores contínuos a partir de variáveis explicativas, assumindo que a variável-alvo pode ser representada como uma combinação linear dessas variáveis. Ele é chamado de "linear" porque estabelece uma relação linear entre as entradas e a saída, ou seja, a previsão é obtida por meio de uma soma ponderada das variáveis ($y = w_1x_1 + w_2x_2 + \ldots + w_nx_n + b$), resultando em uma reta (caso simples) ou um hiperplano (caso múltiplo).

11) Por que a regressão linear é muito utilizada como baseline em análise preditiva?
Porque é um modelo simples, rápido e estável, que fornece uma referência inicial para problemas de regressão. Além disso, possui alta interpretabilidade, permitindo entender diretamente o impacto de cada variável na previsão. Por essas características, é amplamente utilizado como ponto de partida antes da aplicação de modelos mais complexos.

12) Qual é a forma matemática da regressão linear simples e o que representa cada termo?
A regressão linear simples é expressa como $y = wx + b$, onde x é a variável explicativa, w é o coeficiente (peso) e b é o intercepto. O w indica o quanto y varia para cada unidade de x. Já o intercepto b representa o valor de y quando $x = 0$. Em termos geométricos, w representa a inclinação da reta, e b define a posição vertical no plano cartesiano.

13) Como a regressão linear múltipla generaliza o modelo simples?
Na regressão linear múltipla, a variável-alvo é modelada como $y = w_1x_1 + w_2x_2 + \ldots + w_nx_n + b$, onde cada coeficiente w_i representa o impacto da variável x_i na previsão. Isso permite capturar a influência simultânea de múltiplos fatores sobre o resultado.

14) O que significa dizer que o modelo busca o "melhor ajuste"?

Questionário (ref. Aulas 01 a 08)

Significa que o modelo ajusta seus parâmetros (w e b) para minimizar o erro entre os valores reais e os valores previstos, conforme uma função de custo definida (geralmente o erro quadrático médio, MSE). Esse ajuste não é ponto a ponto, mas sim um ajuste global que melhor representa o comportamento dos dados como um todo. Esse processo pode ser realizado por métodos como o gradiente descendente, que atualiza iterativamente os parâmetros na direção que reduz essa função de custo.

15) Em que tipos de problemas a regressão linear é mais adequada e qual é sua principal limitação?

A regressão linear é mais adequada em problemas onde a variável-alvo é contínua e existe uma relação aproximadamente linear entre as variáveis explicativas e o resultado, como previsão de preços, vendas ou indicadores financeiros. Sua principal limitação é justamente assumir essa relação linear; em cenários onde as relações entre as variáveis são complexas ou não lineares, o modelo tende a apresentar baixo desempenho, pois não consegue capturar adequadamente esses padrões.

16) Em que casos deve-se utilizar regressão linear e em que casos deve-se utilizar regressão logística?

A regressão linear deve ser utilizada quando o objetivo é prever valores contínuos, modelando diretamente a saída como uma combinação linear das variáveis explicativas. Já a regressão logística deve ser utilizada quando o objetivo é classificar observações em categorias, estimando a probabilidade de pertencimento a uma classe por meio de uma função sigmoide (ou softmax). Assim, a diferença entre elas está diretamente no tipo de problema: regressão linear para valores numéricos contínuos e regressão logística para problemas de classificação.

Métricas

17) O que é o erro (residual) na regressão linear?

É a diferença entre o valor real observado (y) e o valor previsto pelo modelo (ŷ), isto é, $e = y - \hat{y}$. Esse erro representa a distância vertical entre o ponto observado e o valor estimado pelo modelo (reta ou hiperplano), sendo a base para a definição da função de custo em regressão. Os resíduos são utilizados diretamente no cálculo de métricas como MSE, RMSE e MAE, e também compõem o cálculo de métricas como o coeficiente de determinação (R^2).

18) O que é o coeficiente de determinação (R^2) e o que ele indica?

O coeficiente de determinação (R^2) mede a proporção da variabilidade da variável-alvo que é explicada pelo modelo. Seu valor varia tipicamente entre 0 e 1, onde valores mais próximos de 1 indicam maior capacidade

explicativa. Valores baixos de R^2 indicam baixa variância explicada, o que pode estar associado a baixo desempenho do modelo, embora isso não seja uma regra absoluta.

19) O que é o erro quadrático médio (MSE)?

O MSE (Mean Squared Error) é a média dos quadrados dos resíduos, ou seja, das diferenças entre valores reais e previstos pelo modelo. Sua principal característica é penalizar mais fortemente erros grandes, devido ao uso do quadrado, sendo sensível a outliers.

20) O que é a raiz do erro quadrático médio (RMSE)?

O RMSE (Root Mean Squared Error) é a raiz quadrada do MSE. Ele traz o erro para a mesma escala da variável-alvo, facilitando a interpretação prática do erro, pois está na mesma unidade da variável-alvo. Por exemplo, ao prever o preço de casas em reais, um MSE pode ser 9.000.000 (em reais²), o que dificulta a interpretação. Já o RMSE seria 3.000, permitindo dizer que o modelo erra, em média, cerca de R$ 3.000 nas previsões.

21) O que é o erro absoluto médio (MAE)?

O MAE (Mean Absolute Error) é a média dos valores absolutos dos resíduos, ou seja, das diferenças entre os valores reais e previstos.

22) Por que utilizar tanto MAE quanto RMSE conjuntamente na avaliação de um modelo?

Porque essas métricas capturam comportamentos diferentes do erro. O MAE representa o erro típico médio, tratando todos os erros de forma linear e sendo mais robusto à presença de outliers. Já o RMSE penaliza mais fortemente erros grandes (outliers), sendo mais sensível à presença desses valores extremos. Assim, o uso conjunto permite uma avaliação mais completa do desempenho do modelo.

23) O que pode ser inferido ao comparar os valores de MAE e RMSE?

Quando RMSE e MAE apresentam valores próximos, indica que os erros estão distribuídos de forma mais uniforme. Quando o RMSE é significativamente maior que o MAE, isso indica a presença de erros grandes (outliers), que estão sendo mais penalizados pelo RMSE.

24) Como devem ser interpretados os valores de R^2, MAE, MSE e RMSE na avaliação de um modelo?

O R^2 deve ser maximizado, pois mede o quanto o modelo consegue explicar a variabilidade dos dados — valores mais altos indicam maior capacidade explicativa. Já métricas como MAE, MSE e RMSE devem ser minimizadas, pois são medidas de erro das previsões — valores menores indicam que o modelo comete menos erro.